

CLASSIFICAZIONE DEI TEAM DI DIPENDENTI NELL'INDUSTRIA DELL'ABBIGLIAMENTO.

Rossi Lorenzo, N° matricola 870612 Redolfi Paolo, N° matricola 864677,

Della Penna Paolo, N° matricola 864437

23 novembre, 2022

Abstract

L'obiettivo dello studio è stato trovare un modello soddisfacente per la classificazione dei team di dipendenti che lavorano nell'industria dell'abbigliamento. Attraverso l'utilizzo di variabili riguardanti le prestazioni dei diversi gruppi nel settore si è constatata la possibilità di integrare il modello K-NN e il modello di regressione logistica. Infine, si è verificato quale dei due modelli fosse il più performante nel contesto di analisi in cui si è lavorato si è concluso con la scelta del modello di regressione logistica.

1. Introduzione

L'industria dell'abbigliamento è diventata nel corso della globalizzazione uno dei principali esempi di globalizzazione industriale. Dal settore dell'alta moda fino alla composizione di capi in grandi stock, l'intensità della manodopera è elevata data la numerosità dei processi manuali. Per soddisfare una continua domanda di capi d'abbigliamento i fattori primari sono due: prestazione di produzione, cioè quanto si produce e a quale ritmo; consistenza delle consegne delle aziende B2B (Business-to-Business), basate sulle prestazioni dei dipendenti, a quelle B2C (Business-to-Consumer). È perciò auspicabile, al fine di prendere delle decisioni riguardanti la produzione nel settore dell'abbigliamento, tracciare, analizzare e prevedere le prestazioni di produttività dei team di lavoro delle aziende.

Nell'analisi del dataset "Productivity Prediction of Garment Employees" è inizialmente necessaria la comprensione e riduzione delle variabili. Nello studio si è avuto prima l'obiettivo di trovare e modellizzare dei pattern al fine di dividere i diversi team disponibili e le loro informazioni riguardo agli aspetti produttivi in due classi: "Produttivi" e "Non produttivi". Successivamente si è proceduto con la verifica del modello che meglio descrive il contesto e i dati a disposizione per poter classificare i diversi gruppi di lavoro.

2. Materiali

2.1 Descrizione del dataset

Il dataset “Productivity Prediction of Garment Employees” è composto da 1197 osservazioni e 15 variabili. I dati sono stati raccolti manualmente e convalidati da esperti del settore. Le osservazioni corrispondono alle rilevazioni effettuate nei diversi team in una determinata data e gli attributi descrivono il processo di produzione degli indumenti e della produttività dei dipendenti.

2.2 Descrizione delle variabili presenti nel dataset

Le 15 variabili del dataset sono:

- DATE: data della rilevazione codificata come MM-GG-AAAA.
- QUARTER: porzione del mese in cui è stata effettuata la rilevazione. Può assumere una delle cinque modalità tra “Quarter1”, “Quarter2”, “Quarter3”, “Quarter4” e “Quarter5”. Le prime quattro porzioni sono composte da sette giorni ciascuna, mentre “Quarter5” è composto da massimo 3 giorni, cioè quelli restanti per terminare il mese.
- Department: reparto del processo produttivo dove è stata effettuata la rilevazione. Può assumere una delle due modalità tra “sweing” e “finishing”.
- Day: giorno della settimana in cui è stata effettuata la rilevazione. Può assumere una delle sei modalità tra “Monday”, “Tuesday”, “Wednesday”, “Thursday”, “Saturday” e “Sunday”.
- Team: numero del team dove è stata effettuata la rilevazione. I numeri dei team oggetto di studio sono dal team 1 al team 12.
- Targeted_productivity: produttività target stabilita dall’ente che è a capo dei team. Il valore è assegnato ad ogni squadra per ogni giorno ed è compreso da 0 e 1.
- SMV: Standard Minute Value. Rappresenta il tempo assegnato per la portata a terminare di un lavoro.
- Wip: Work in progress. Include il numero di elementi non finiti per il completamento dei prodotti.
- Over_time: rappresenta la quantità di ore di lavoro straordinario effettuate da ciascun team, espressa in minuti.
- Incentive: rappresenta l'ammontare dell'incentivo finanziario (in BDT) che consente o incentiva un determinato il prodotto.
- Idle_time: quantità di tempo in cui la produzione è stata interrotta per diversi motivi per un team.
- Idle_men: numero di lavoratori inattivi a causa dell'interruzione della produzione in un team.
- No_of_style_change: numero di modifiche nella conformazione un particolare prodotto.
- No_of_workers: numero di dipendenti in ogni team.
- Actual_productivity: produttività effettiva registrata. Il valore è compreso tra 0 e 1.

Rappresenta la variabile target per le nostre analisi.

2.3 Codificazione e valori mancanti

Si nota che per effettuare delle analisi prive di errori ed omissioni è necessario codificare le variabili qualitative Quarter, Department e Day in valori numerici, e anche la variabile target in due classi.

Nel dataset sono presenti dei valori mancanti, contrassegnati con la notazione NA, nella variabile Wip che dovrà essere oggetto di un'ulteriore analisi finalizzata per un corretto trattamento dei dati.

3. Metodi

3.1 Metodi del pre-processing

Nell'analisi esplorativa del dataset si sono usati i seguenti metodi di pre-processing:

1. Codifica delle variabili: trasformazione delle variabili qualitative con l'assegnazione di un valore numerico ad ogni modalità.
2. Suddivisione dataset: divisione dei nostri dati in training set, validation set e test set.
3. Trasformazioni in classi della variabile target: identificazione di un valore soglia x e assegnazione della classe 0 alle osservazioni dove la variabile di interesse è minore o uguale a x , assegnazione della classe 1 alle osservazioni valori maggiori di x .
4. Verifica presenza missing values e casewise deletion: si individua la presenza di dati mancanti attraverso tabelle di frequenza e si effettua una casewise deletion, strategia passiva che consiste nell'eliminazione di una variabile dove vi è un'alta concentrazione di valori mancanti.
5. Analisi correlazioni tra variabili: analisi della matrice di correlazione tra le variabili del training set. Eliminazione variabili altamente correlare: si individuano le variabili con un indice di correlazione sopra una certa soglia e si decide di eliminarle.
6. Analisi distribuzione delle variabili: analisi delle variabili attraverso boxplot e istogrammi.
7. Eliminazione variabili non significative: si escludono le variabili dove i valori assunti dalle osservazioni non sono considerate utili al fine dell'analisi.
8. Normalizzazione: tecnica utilizzata data la distribuzione non normale dei dati.

3.2 Verifica delle assunzioni per l'utilizzo dell'LDA e QDA

Per verificare una varianza comune tra covariate si effettua un'analisi grafica mediante l'utilizzo di boxplot condizionati alle rispettive classi.

Poi, in primo luogo, per verificare l'ipotesi di normalità delle variabili si è svolta un'ulteriore

analisi dei grafici e successivamente si è fatto ricorso al test di Shapiro-Wilk che ha come ipotesi nulla che la distribuzione sia normale.

3.3 K-Nearest Neighbours

Il K-Nearest Neighbours (K-NN) è un metodo di classificazione non parametrico. Scelto inizialmente un numero $K \in \mathbb{N}$ (parametro di tuning), viene calcolata la distanza tra una nuova osservazione x_i ($i = 1, 2, \dots, n$) e ogni altra osservazione, poi vengono ordinate le distanze e identificate le K osservazioni più vicine. Infine, il classificatore individua le classi associate alle K osservazioni più vicine a x_i ed individua la classe più comune per usarla come previsione del nuovo punto. Questo metodo è ottimale nei casi in cui la linea di confine per la divisione in classi sia molto complicata.

3.4 Regressione logistica

Data una variabile risposta dicotomica il modello di regressione logistica si basa sulla probabilità di possedere una delle classi condizionata al vettore delle covariate X . Viene utilizzata la distribuzione logistica:

$$\Pr(Y = k|X) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p}},$$

in modo da avere una funzione limitata superiormente dalla retta $y = 1$ e limitata inferiormente dalla retta $y = 0$. Inoltre, viene applicata la funzione logit:

$$\text{logit}(\Pr(Y = k|X)) = \ln \left(\frac{\Pr(Y = k|X)}{1 - \Pr(Y = k|X)} \right).$$

Così ottenendo il rapporto fra probabilità associate ad una variabile dicotomica, definito come odds. I parametri $\beta_1, \beta_2, \dots, \beta_p$ vengono stimati attraverso il metodo della massima verosimiglianza.

La regressione logistica individua una linea di confine lineare.

4. Risultati

4.1 Pre -processing

Nella prima fase di approccio al dataset si è deciso innanzitutto di eliminare la variabile Date poiché ha solo un ruolo formale nella presentazione ed inoltre le informazioni riguardanti possibili stagionalità sono contenute nelle variabili Quarter e Day. In seguito vi è stata la codifica delle variabili qualitative Quarter, Day e Department rispettivamente con valori da 1 a 5 e valori da 1 a 6 per le prime due, e con valori 0 e 1 per la variabile Department. Questa procedura ha reso possibile l'utilizzo delle variabili nell'analisi poiché sono diventate quantitative. Infine è stato diviso il dataset con un campionamento casuale delle osservazioni ed è stato diviso in:

- training set, contiene l'80% delle osservazioni ed è stato suddiviso a sua volta in training piccolo, contenente il 60% delle osservazioni, e validation set contenente il restante 40%;
- test set, contiene il 20% delle osservazioni.

Da questo punto l'analisi esplorativa è stata svolta sul training piccolo.

Dato l'obiettivo del lavoro, è stato necessario determinare un valore soglia della variabile target Actual_productivity per distinguere i team produttivi da quelli non produttivi; perciò, è stato preso come riferimento il valore medio della variabile Targeted_productivity che ci dà un'informazione riguardante le richieste di produttività degli enti a capo del settore dell'abbigliamento ed è stato valutato come valore di confine per distinguere le due classi. La variabile target apparterrà alla classe 0 (Non produttivi), quando il valore di Actual_productivity sarà minore o uguale a 0.7, altrimenti apparterrà alla classe 1 (Produttivi) (Figura 1).

Ai valori anomali di questa variabile che assumevano valori maggiori di 1, quindi fuori dal range definito in precedenza, è stato assegnato la classe 1, poiché rappresentano una produttività massima.




Figura 1. Istogramma delle frequenze della variabile target. La linea rossa identifica il valore 0.7 per l'assegnazione delle classi.

Nella seconda fase di analisi il primo passo è stato l'individuazione di eventuali missing values. I valori mancanti sono presenti esclusivamente nella variabile Wip e rappresentano il 43% delle osservazioni del training piccolo. Data l'alta concentrazione di NA e la limitatezza del problema ad una sola variabile si è proceduto con l'eliminazione della covariata Wip tramite casewise deletion.

Come terza fase si è proceduto con lo studio delle correlazioni tra covariate. Come di può vedere dalla Figura 2 le variabili con

$$|\rho(x_i, x_j)| > 0.9,$$

(dove $\rho(x_i, x_j)$ è l'indice di correlazione lineare tra le i-esima e la j-esima covariata) sono le coppie No_of_workers-Department e No_of_workers-SMV. Questa elevata correlazione può essere spiegata dal fatto che i team assegnati ai due reparti hanno comunemente numeri diversi di membri e che il tempo assegnato per la conclusione di un lavoro sarà minore all'aumento del numero di persone che ne prendono parte.




Figura 2. Correlazione delle variabili.

Si decide quindi di eliminare dalle nostre analisi la variabile No_of_workers.

Come quarta fase si sono analizzati i boxplot e gli istogrammi delle variabili. Si è notato dai boxplot di Idle_time, Idle_man e No_of_style_change (Figura 3) la presenza di valori anomali, questo perché si hanno elevate percentuali di valori pari a 0 rispetto alle osservazioni del training piccolo come si può vedere nella Tabella 1.




Figura 3. Boxplot variabili Idle_time (A) e Idle_man (B).

Variabile	Percentuale di 0 presenti
Idle_time	98%
Idle_man	98%

Tabella 1. Percentuali di valori pari a 0 rispetto alle osservazioni del training piccolo.

Data la situazione si è scelto di escludere dall'analisi queste tre variabili poiché con il valore 0 così predominante non vengono trasmesse delle informazioni significative.

Con il fine di studiare le distribuzioni delle variabili, solo per due di queste è esplicativo l'istogramma delle frequenze: Smv e Over_time. Questo accade perché le altre variabili assumono solo un range limitato di valori, mentre Smv e Over_time possiedono un range più ampio.

Si può notare dalla Figura 4 che le distribuzioni sono sbilanciate.




Figura 4. Istogrammi delle frequenze delle variabili: a sinistra quello di Smv e a destra quello di Over_time.

Una possibilità per risolvere questo problema è applicare una trasformazione logaritmica, ma anche in questo modo, le distribuzioni non migliorano (Figura 5).




Figura 5. Istogrammi delle frequenze delle variabili trasformate: a sinistra quello di Smv e a destra quello di Over_time.

Dato che le distribuzioni delle variabili non sono note e dagli istogrammi delle frequenze non si può dedurre che siano normali si è optato per una normalizzazione delle covariate in modo tale che i valori siano contenuti all'interno dell'intervallo 0 e 1.

A questo punto il training piccolo è quello con cui andare avanti con la modellizzazione e si può vedere l'eventuale presenza di una classe maggioritaria.

Training piccolo	
0	1
33%	67%

Tabella 2.

Validation set	
0	1
29%	71%

Tabella 3.

Test set	
0	1
28%	72%

Tabella 4.

Frequenze classi nel training piccolo, validation set e test set.

Dalle tabelle (Tabella 2, Tabella 3, Tabella 4,) si può notare come nel training piccolo, nel validation set e nel test set il numero di osservazioni classificate con 1 è molto maggiore rispetto a quelle classificate con 0.

4.2 Verifica assunzioni per l'utilizzo della analisi discriminante lineare (LDA) e l'analisi discriminante quadratica (QDA)

Si è voluto verificare le assunzioni per l'applicabilità dell'analisi discriminante lineare (LDA) e dell'analisi discriminante quadratica (QDA).

Prima di tutto per verificare se le nostre variabili hanno varianza comune utilizziamo i boxplot condizionati alla classe di appartenenza (Figura 6).




Figura 6. Boxplot delle variabili condizionate alle classi 0 e 1 di Actual_productivity.

Dai boxplot si nota che quasi tutte le variabili, condizionate alla classe, non sembrano condividere la stessa matrice di varianza.

Si segue con la verifica la normalità attraverso un'analisi grafica delle curve di densità sempre condizionando alla classe di appartenenza (Figura 7).




Figura 7. Densità delle variabili condizionate alle classi 0 e 1 di Actual_productivity.

Si può immediatamente notare come tutte le variabili disponibili, condizionate alla classe, non seguano un andamento di normalità.

Per andare a verificare tale risultato si è utilizzato il test della normalità di Shapiro-Wilk, con il risultato che nessun p-value ottenuto delle variabili condizionate alle classi non risulta significativo ad un livello del 5%.

4.3 Applicazione del metodo della Regressione Logistica

Volendo descrivere la relazione di dipendenza tra il possesso di una classe assunta dalla variabile target e più variabili indipendenti, si è inizialmente ipotizzato di stimare un modello che utilizzi la regressione logistica, in modo che consideri tutte le variabili esplicative e tutte le osservazioni a nostra disposizione, ottenendo un AIC pari a 596.66.

A questo punto si è tentato di trovare un modello migliore, sempre utilizzando la regressione logistica, in modo da poter minimizzare l'AIC.

Come prima cosa si è andato a verificare la presenza di outliers utilizzando il grafico delle influenze, e si è immediatamente notato la presenza di un'osservazione anomala, la numero 1150 (Figura 8).




Figura 8. Grafico dell'influenze.

Successivamente si è andati a controllare se il modello con l'esclusione di quell'osservazione influente e della variabile Quarter migliorasse effettivamente, e calcolando nuovamente l'AIC si è trovato un valore di pari a 593.25, inferiore al livello precedente.

Tramite il test ANOVA (Tabella 5), si è verificato quali variabili fossero meno significative nella previsione in modo da poterle rimuovere dal modello, ma con la loro eliminazione non si ottiene produceva una riduzione dell'AIC, perciò si preferisce valutare il modello che considera tutte le covariate a disposizione.

Variabile	P-value
Department	0.002027
Day	0.139838
Team	0.014109
Targeted_productivity	$2.2 \cdot 10^{-16}$
Smv	$4.2 \cdot 10^{-6}$
Incentive	$6.7 \cdot 10^{-6}$
No_of_style_change	0.144905

Tabella 5. Significatività delle variabili

Per il modello di regressione logistica si è quindi deciso di utilizzare le seguenti variabili:

Department, Day, Team, Targeted_productivity, Smv, Incentive e No_of_style_change.

Deciso il modello da utilizzare si verifica il comportamento di esso nel validation set attraverso l'accuratezza, specificità e sensibilità.

Accuratezza	Sensibilità	Specificità
78.1%	92%	48.3%

Tabella 6. Accuratezza, sensibilità e specificità del modello di regressione logistica nel validation set.

Si nota dalla Tabella 6 l'alta sensibilità e la bassa specificità; quindi, si può dedurre che nel validation set il modello di regressione logistica classifica correttamente le osservazioni come la classe 1, questo anche perché è maggioritaria.

Un ulteriore strumento di verifica del nostro modello è l'AUC, misurato calcolando l'area sottesa alla curva di ROC e nel nostro caso pari a 82,12% (Figura 9).




Figura 9. Curva di ROC per il modello di regressione logistica.

4.4 Applicazione K-Nearest Neighbours

Si è a conoscenza dell'esistenza di una classe maggioritaria e si è deciso di testare un numero di K valori non troppo elevato, perché all'aumentare di K, si avrà un problema di overfitting.

Si stima dunque il modello con i primi 20 valori di K, e valutando la capacità di classificazione con l'error rate, otteniamo la miglior performance con K=9, come si può notare nella Figura 10.




Figura 10. Error rate per ogni K da 1 a 10.

Utilizzando quindi il metodo dei K-NN con K=9 si ottengono i seguenti valori nel validation set di accuratezza, specificità e sensibilità (Tabella 7).

Accuratezza	Sensibilità	Specificità
70.5%	99.6%	0.1%

Tabella 7. Accuratezza, sensibilità e specificità del modello K-NN con K = 9 nel validation set.

Si ottiene una sensibilità quasi pari ad 1 poiché data la maggiore presenza della classe 1 la probabilità che le osservazioni meno distanti da quella presa in considerazione è molto alta.

5. Conclusioni

Metodo	Accuratezza	Sensibilità	Specificità
Regressione logistica	76.3%	88.5%	44.8%
K-NN	72.5%	89.0%	31.0%

Tabella 8. Accuratezza, sensibilità e specificità della regressione logistica con le variabili selezionate e del modello K-NN con K = 9 nel test set.

Si nota che le variabili non assumono una particolare distribuzione, e quindi si poteva ipotizzare che il modello K-NN sarebbe stato quello più performante. I dati però non confermano questa teoria; nonostante l'accuratezza sia simile al modello di regressione e la sensibilità sia buona, ciò che penalizza questo modello è la bassa specificità, probabilmente causata da un problema di

underfitting (Tabella 8).

Il modello migliore tra quelli analizzati è quindi risultato essere il modello di regressione logistica che ha un'accuratezza di circa quattro punti percentuali maggiore del modello K-NN e una specificità nettamente maggiore, anche se sempre relativamente bassa.

Si può concludere che il metodo del K-NN tende ad un quasi certa classificazione dei team come produttivi quando lo sono realmente, ma sbagliando completamente nell'identificazione della classe opposta; questo modello dunque non è ideale per l'identificazione dei team produttivi, in quanto, con le variabili indipendenti a nostra disposizione, tenderà ad identificarne la grande maggioranza come produttivi e non la reale percentuale di questi ultimi.

Utilizzando invece il metodo da noi prescelto, quello della regressione logistica, si ha un errore più basso e con buona certezza sarà un metodo con un maggiore bilanciamento dell'identificazione delle due classi di lavoratori.

Bibliografia

[1] Md Shamsur Rahim and Abdullah Al Imran and Tanvir Ahmed, *Mining the Productivity Data of Garment Industry*,

<https://archive.ics.uci.edu/ml/datasets/Productivity+Prediction+of+Garment+Employees>.

[2] G. James, D. Witten and T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*.

[3] M. Borrotti, *Data Mining, Classificatore K-Nearest-Neighbours*,

https://elearning.unimib.it/pluginfile.php/1406298/mod_resource/content/1/03_knn.pdf.

[4] M. Borrotti, *Data Mining, Regressione logistica*,

https://elearning.unimib.it/pluginfile.php/1411246/mod_resource/content/1/05_LogisticRegression.pdf.